

Лекция 1. Одномерные временные ряды.

Белый шум. Основные ARMA-модели. Операторы лага и полиномы лага.

Белый шум.

Основным элементом при построении моделей временных рядов будет процесс *белого шума*, который мы будем обозначать ε_t . В простейшем случае

$$\varepsilon_t \sim i.i.d. N(0, \sigma_\varepsilon^2).$$

Отметим три следствия этого предположения:

1. $E(\varepsilon_t) = E(\varepsilon_t | \varepsilon_{t-1}, \varepsilon_{t-2}, \dots)$
 $= E(\varepsilon_t | \text{вся информация к моменту } t - 1) = 0.$
2. $E(\varepsilon_t \varepsilon_{t-j}) = \text{Cov}(\varepsilon_t \varepsilon_{t-j}) = 0.$
3. $\text{Var}(\varepsilon_t) = \text{Var}(\varepsilon_t | \varepsilon_{t-1}, \varepsilon_{t-2}, \dots)$
 $= \text{Var}(\varepsilon_t | \text{вся информация к моменту } t - 1) = \sigma_\varepsilon^2.$

Первое и второе свойства – это *отсутствие какой-либо сериальной корреляции или предсказуемости*. Третье свойство – это *условная гомоскедастичность*, т.е. постоянство условной дисперсии.

Позже мы будем рассматривать более общие процессы в качестве основного элемента модели. Например, мы можем предполагать выполнение 2) и 3) без предположения нормальности распределения. В этом случае ε_t не обязательно независимы. Мы можем предполагать только первое свойство, в этом случае говорят, что ε_t является последовательностью *мартингал-*

разностей (т.е. накопленные суммы $S_t = \varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_t$ образуют мартингал и $\varepsilon_t = S_t - S_{t-1}$).

Сам по себе процесс ε_t не столь интересен. Из-за независимости последующие значения ε_{t+j} никак не связаны со значением ε_t . В более реалистичных моделях рассматриваются комбинации значений ε_t .

Основные ARMA-модели.

Мы будем изучать модели, в которых используются различные линейные комбинации процесса белого шума. Например:

$$AR(1): x_t = \phi x_{t-1} + \varepsilon_t$$

$$MA(1): x_t = \varepsilon_t + \theta \varepsilon_{t-1}$$

$$AR(p): x_t = \phi_1 x_{t-1} + \phi_2 x_{t-2} + \dots + \phi_p x_{t-p} + \varepsilon_t$$

$$MA(q): x_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

$$ARMA(p, q): x_t = \phi_1 x_{t-1} + \phi_2 x_{t-2} + \dots + \phi_p x_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}.$$

Как мы видим, каждая из моделей даёт способ построения последовательности $\{x_t\}$ по заданной последовательности реализаций $\{\varepsilon_t\}$ и начальным значениям процесса x_t .

Операторы лага и полиномы от них.

Оператор лага удобен для описания и представления ARMA моделей. Он сдвигает индекс назад на одну единицу времени: $Lx_t = x_{t-1}$. Иначе говоря, оператор лага из исходного ряда $\{x_t\}$ производит новый ряд, который отличается от исходного тем, что

«сдвинут» на единицу времени назад. Из определения легко получаем:

$$L^2 x_t = L(Lx_t) = Lx_{t-1} = x_{t-2}.$$

$$L^j x_t = x_{t-j}, \quad L^{-j} x_t = x_{t+j}.$$

Можно ввести также **полиномы от оператора лага**, например

$$a(L)x_t = (a_0 L^0 + a_1 L^1 + a_2 L^2)x_t = a_0 x_t + a_1 x_{t-1} + a_2 x_{t-2}.$$

Используя эти обозначения, мы можем переписать предыдущие модели в виде:

$$AR(1): (1 - \phi L)x_t = \varepsilon_t$$

$$MA(1): x_t = (1 + \theta L)\varepsilon_t$$

$$AR(p): (1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p)x_t = \varepsilon_t$$

$$MA(q): x_t = (1 + \theta_1 L + \dots + \theta_q L^q)\varepsilon_t$$

$$ARMA(p, q): (1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p)x_t = (1 + \theta_1 L + \dots + \theta_q L^q)\varepsilon_t$$

или просто

$$AR: a(L)x_t = \varepsilon_t$$

$$MA: x_t = b(L)\varepsilon_t$$

$$ARMA: a(L)x_t = b(L)\varepsilon_t$$

Использование операторов лага в ARMA-моделях.

ARMA модели не определяются рядом однозначно. Временной ряд с заданным совместным распределением вектора $\{x_0, \dots, x_T\}$ может, как правило, быть представлен множеством ARMA моделей. Часто бывает удобно работать с разными представлениями. Например, самое короткое полиномиальное представление является самым удобным для

работы во многих случаях. Представление AR – самое удобное для задач оценивания, так как МНК - гипотезы часто всё ещё применимы. Представление MA выражает x_t в виде линейных комбинаций независимых случайных величин в правой части уравнения. Для многих целей, таких, как нахождение дисперсий и ковариаций, это самое удобное представление.

От AR(1) к MA (∞) с помощью рекурсии.

Начнём с модели AR(1)

$$x_t = \phi x_{t-1} + \varepsilon_t$$

Последовательно подставляя, получим

$$\begin{aligned} x_t &= \phi(\phi x_{t-2} + \varepsilon_{t-1}) + \varepsilon_t = \phi^2 x_{t-2} + \phi \varepsilon_{t-1} + \varepsilon_t = \\ \dots &= \phi^k x_{t-k} + \phi^{k-1} \varepsilon_{t-k+1} + \dots + \phi^2 \varepsilon_{t-2} + \phi \varepsilon_{t-1} + \varepsilon_t. \end{aligned}$$

Таким образом, AR(1) всегда можно представить как ARMA (k,k-1).

В случае, когда $|\phi| < 1$ имеем $\lim_{k \rightarrow \infty} \phi^k x_{t-k} = 0$ и

$$x_t = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}$$

То есть, AR(1) модель может быть представлена как MA(∞) модель.

Сходимость ряда понимается в среднеквадратическом.

От AR(1) к MA (∞) с помощью операторов лага.

То, что мы проделали в предыдущем параграфе, гораздо легче проделать *с использованием операторов лага*. Чтобы обратить модель AR(1), запишем её как

$$(1 - \phi L)x_t = \varepsilon_t.$$

Естественный способ «обратить» $AR(1)$ – это записать модель в виде

$$x_t = (1 - \phi L)^{-1} \varepsilon_t.$$

Какой смысл придать выражению $(1 - \phi L)^{-1}$? Вспомним, что

$$(1 - z)^{-1} = 1 + z + z^2 + \dots \quad \text{для } |z| < 1$$

Из этого разложения (полагая $\phi L = z$) получим

$$x_t = (1 - \phi L)^{-1} \varepsilon_t = (1 + \phi L + \phi^2 L^2 + \phi^3 L^3 + \dots) \varepsilon_t = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j},$$

То есть получаем прежний ответ. Позже мы дадим некоторое обоснование тому, почему такие формальные методы обращения «работают». Заметим, что не все ARMA процессы обратимы.

От $AR(p)$ к $MA(\infty)$, от $MA(q)$ к $AR(\infty)$, разложение полиномов лага на множители, разложение на простые дроби.

Для модели $AR(1)$ переход к $MA(\infty)$ осуществляется одинаково просто как методом рекурсий, так и методом обращения. Уже для модели $AR(2)$ это не так: метод обращения позволяет значительно упростить вычисления. Рассмотрим $AR(2)$ модель

$$x_t = \phi_1 x_{t-1} + \phi_2 x_{t-2} + \varepsilon_t$$

или, записывая через полиномы лага,

$$(1 - \phi_1 L - \phi_2 L^2) x_t = \varepsilon_t.$$

Применим *метод разложения на множители*. Ищем λ_1 и λ_2 такие, что

$$(1 - \phi_1 L - \phi_2 L^2) = (1 - \lambda_1 L)(1 - \lambda_2 L).$$

Это приводит к системе уравнений для λ_1 и λ_2

$$\lambda_1 \lambda_2 = -\phi_2$$

$$\lambda_1 + \lambda_2 = \phi_1$$

(Заметим, что λ_1 и λ_2 могут быть комплексными числами).

Обратим исходный ряд

$$(1 - \phi_1 L - \phi_2 L^2)x_t = (1 - \lambda_1 L)(1 - \lambda_2 L)x_t = \varepsilon_t,$$

$$x_t = (1 - \lambda_1 L)^{-1}(1 - \lambda_2 L)^{-1}\varepsilon_t =$$

$$\left(\sum_{j=0}^{\infty} \lambda_1^j L^j\right) \left(\sum_{j=0}^{\infty} \lambda_2^j L^j\right) \varepsilon_t = \sum_{j=0}^{\infty} \left(\sum_{k=0}^j \lambda_1^k \lambda_2^{j-k}\right) L^j \varepsilon_t.$$

Есть другой метод получения $MA(\infty)$ модели из $AR(2)$. Он связан с **разложением на простые дроби**. Будем искать a и b из условия

$$\frac{1}{(1 - \lambda_1 L)(1 - \lambda_2 L)} = \frac{a}{(1 - \lambda_1 L)} + \frac{b}{(1 - \lambda_2 L)} =$$

$$\frac{a(1 - \lambda_2 L) + b(1 - \lambda_1 L)}{(1 - \lambda_1 L)(1 - \lambda_2 L)}.$$

Числитель правой части последнего равенства должен быть равен 1, поэтому

$$a + b = 1$$

$$a\lambda_2 + b\lambda_1 = 0.$$

Откуда

$$a = \frac{\lambda_1}{\lambda_1 - \lambda_2}, b = \frac{\lambda_2}{\lambda_2 - \lambda_1},$$

поэтому

$$\frac{1}{(1 - \lambda_1 L)(1 - \lambda_2 L)} = \frac{\lambda_1}{\lambda_1 - \lambda_2} \frac{1}{(1 - \lambda_1 L)} + \frac{\lambda_2}{\lambda_2 - \lambda_1} \frac{1}{(1 - \lambda_2 L)}.$$

Таким образом, для x_t получаем следующее выражение

$$x_t = \frac{\lambda_1}{\lambda_1 - \lambda_2} \sum_{j=0}^{\infty} \lambda_1^j \varepsilon_{t-j} + \frac{\lambda_2}{\lambda_2 - \lambda_1} \sum_{j=0}^{\infty} \lambda_2^j \varepsilon_{t-j} =$$

$$\sum_{j=0}^{\infty} \left(\frac{\lambda_1}{\lambda_1 - \lambda_2} \lambda_1^j + \frac{\lambda_2}{\lambda_2 - \lambda_1} \lambda_2^j \right) \varepsilon_{t-j}$$

Эта формула напоминает решение разностного или дифференциального уравнения второго порядка, которое представляется в виде суммы двух экспонент или (если λ комплексное) суммы двух затухающих синусоидальных и косинусоидальных волн. В случае AR(p)-модели можно действовать аналогичным образом. Имеются программы, которые находят корни полиномов произвольного порядка. Затем можно перемножить полиномы вида $(1 - \lambda_i L)$ или искать разложение на простые дроби. Можно также использовать сведение одномерной модели AR(p) к векторной модели AR(1), что позволяет упростить вычисления. Отметим снова, что не каждую модель AR(2) можно обратить. Нужно требовать, чтобы $|\lambda| < 1$, и, используя выражение λ через ϕ , можно найти допустимую область значений ϕ_1 и ϕ_2 . Если не оговорено противное, мы будем рассматривать только обратимые ARMA модели. После наших рассмотрений переход от MA к AR(∞) очевиден. Запишем MA в виде

$$x_t = b(L)\varepsilon_t.$$

Тогда AR(∞) представление имеет вид

$$b(L)^{-1}x_t = \varepsilon_t.$$

Сводка допустимых операций с полиномиальными лагами.

Коротко говоря, с полиномиальными лагами можно обращаться во многом как с обычными полиномами, если заменить L на z , где z комплексное число. Перечислим допустимые операции:

1. Полиномиальные лаги *можно перемножать*

$$\begin{aligned} a(L)b(L) &= (a_0 + a_1L + \dots)(b_0 + b_1L + \dots) = \\ &= a_0b_0 + (a_0b_1 + a_1b_0)L + \dots \end{aligned}$$

2. Полиномиальные лаги *коммутируют*

$$a(L)b(L) = b(L)a(L)$$

3. Полиномиальные лаги можно *возводить в натуральные степени*

$$a(L)^2 = a(L)a(L)$$

4. Их можно *обращать, разлагая на множители* и обращая каждый сомножитель отдельно

$$a(L) = (1 - \lambda_1 L)(1 - \lambda_2 L) \dots$$

$$a^{-1}(L) = (1 - \lambda_1 L)^{-1}(1 - \lambda_2 L)^{-1} \dots =$$

$$\left(\sum_{j=0}^{\infty} \lambda_1^j L^j \right) \left(\sum_{j=0}^{\infty} \lambda_2^j L^j \right) \dots = \frac{c_1}{(1 - \lambda_1 L)} + \frac{c_2}{(1 - \lambda_2 L)} + \dots$$

Один полезный приём.

Помимо разложения на множители и на простые дроби существует много полезных приёмов при работе с полиномиальными лагами. Рассмотрим один из них. Можно обратить полиномы конечного порядка, просто приравнивая коэффициенты при одинаковых степенях L . Пусть имеется модель $a(L)x_t = b(L)\varepsilon_t$, и мы хотим найти МА представление вида $x_t = d(L)\varepsilon_t$. Прямое вычисление по формуле $x_t = a(L)^{-1}b(L)\varepsilon_t$ часто бывает затруднительным. Вместо этого будем искать $d(L)$ из соотношения

$$a(L)x_t = a(L)d(L)\varepsilon_t = b(L)\varepsilon_t$$

То есть $a(L)d(L) = b(L)$ и достаточно приравнять коэффициенты при одинаковых степенях L . Например, пусть $a(L) = a_0 + a_1L$, $b(L) = b_0 + b_1L + b_2L^2$. Имеем

$$b_0 + b_1L + b_2L^2 = (a_0 + a_1L)(d_0 + d_1L + d_2L^2 + \dots)$$

Приравнивая, получим систему уравнений

$$b_0 = a_0d_0$$

$$b_1 = a_1d_0 + a_0d_1$$

$$b_2 = a_1d_1 + a_0d_2$$

$$0 = a_1d_{j-1} + a_0d_j, \quad j \geq 3.$$

Система легко решается относительно d_j .