

## Лекция 2. Автоковариационная и автокорреляционная функции.

Рассматриваемые в этой лекции ряды мы предполагаем стационарными в широком смысле. Поэтому определяемые ниже автоковариационная и автокорреляционная функции зависят только от разности моментов времени.

**Определение.** Автоковариационная функция ряда  $x_t$  определяется следующим образом

$$\gamma_j = \text{Cov}(x_t x_{t-j}) = E(x_t x_{t-j}).$$

(напомним, что мы рассматриваем ряды с  $E x_t = 0$ ).

Автокорреляционная функция ряда  $x_t$  определяется следующим образом

$$\rho_j = \frac{\gamma_j}{\text{var}(x_t)} = \frac{\gamma_j}{\gamma_0}.$$

Автоковариации и автокорреляции дают один из простейших способов описания совместных распределений наблюдаемого временного ряда. Например, корреляция между  $x_t$  и  $x_{t+1}$  является мерой того, насколько устойчив временной ряд, насколько, скажем, тенденция сегодняшнего дня будет воспроизведена завтра.

### Автоковариации и автокорреляции различных ARMA процессов.

В этом параграфе мы вычислим автоковариационные и автокорреляционные функции некоторых основных временных рядов.

**Белый шум.** Поскольку мы предположили, что  $\varepsilon_i \sim i. i. d. \mathcal{N}(0, \sigma_\varepsilon^2)$ , очевидно, что

$$\gamma_0 = \sigma_\varepsilon^2, \gamma_j = 0 \text{ для } j \neq 0$$

$$\rho_0 = 1, \quad \rho_j = 0 \text{ для } j \neq 0.$$

**МА (1).** Модель имеет вид

$$x_t = \varepsilon_t + \theta \varepsilon_{t-1}.$$

Автоковариации:

$$\gamma_0 = \text{var}(x_t) = \text{var}(\varepsilon_t + \theta \varepsilon_{t-1}) = \sigma_\varepsilon^2 + \theta^2 \sigma_\varepsilon^2 = (1 + \theta^2) \sigma_\varepsilon^2,$$

$$\gamma_1 = E(x_t x_{t-1}) = E((\varepsilon_t + \theta \varepsilon_{t-1})(\varepsilon_{t-1} + \theta \varepsilon_{t-2})) = E(\theta \varepsilon_{t-1}^2) = \theta \sigma_\varepsilon^2.$$

$$\gamma_2 = E(x_t x_{t-2}) = E((\varepsilon_t + \theta \varepsilon_{t-1})(\varepsilon_{t-2} + \theta \varepsilon_{t-3})) = 0.$$

$$\gamma_j = 0, j \geq 3.$$

Автокорреляции:

$$\rho_0 = 1, \rho_1 = \frac{\theta}{1 + \theta^2}, \rho_2, \rho_3, \dots = 0.$$

**МА (2).** Модель:

$$x_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}.$$

Автоковариации:

$$\gamma_0 = E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})^2] = (1 + \theta_1^2 + \theta_2^2) \sigma_\varepsilon^2,$$

$$\gamma_1 = E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})(\varepsilon_{t-1} + \theta_1 \varepsilon_{t-2} + \theta_2 \varepsilon_{t-3})] =$$

$$(\theta_1 + \theta_1 \theta_2) \sigma_\varepsilon^2$$

$$\gamma_2 = E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})(\varepsilon_{t-2} + \theta_1 \varepsilon_{t-3} + \theta_2 \varepsilon_{t-4})] = \theta_2 \sigma_\varepsilon^2.$$

$$\gamma_3, \gamma_4, \gamma_5, \dots = 0.$$

Автокорреляции:

$$\rho_0 = 1, \rho_1 = \frac{(\theta_1 + \theta_1 \theta_2)}{1 + \theta_1^2 + \theta_2^2}, \rho_2 = \frac{\theta_2}{1 + \theta_1^2 + \theta_2^2}, \rho_3, \rho_4, \dots = 0.$$

**MA(q), MA( $\infty$ ).**

Теперь должно быть ясно, как считать ковариации для общих моделей скользящего среднего. Для модели **MA( $\infty$ )**

$$x_t = \theta(L)\varepsilon_t = \sum_{j=0}^{\infty} (\theta_j L^j) \varepsilon_t$$

для автоковариаций получаем

$$\gamma_0 = \text{var}(x_t) = \left( \sum_{j=0}^{\infty} \theta_j^2 \right) \sigma_{\varepsilon}^2,$$

$$\gamma_k = \sum_{j=0}^{\infty} \theta_j \theta_{j+k} \sigma_{\varepsilon}^2.$$

Здесь  $\theta_0 = 1$ . Автоковариации для модели **MA(q)** получаются из автоковариаций для модели **MA( $\infty$ )**, если в формулах положить  $\theta_{j+k} = 0$  для  $j+k > q$ . Формулы для  $\rho_j$  немедленно следуют из соотношения  $\rho_j = \frac{\gamma_j}{\gamma_0}$ .

**AR (1).** Есть два способа вычисления автоковариаций для этого процесса. Первый способ заключается в переходе к **MA( $\infty$ )** и использовании вышеприведённых формул для процесса **MA( $\infty$ )**.  
Имеем:

$$(1 - \phi L)x_t = \varepsilon_t \Rightarrow x_t = (1 - \phi L)^{-1} \varepsilon_t = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j},$$

Поэтому

$$\gamma_0 = \left( \sum_{j=0}^{\infty} \phi^{2j} \right) \sigma_{\varepsilon}^2 = \frac{1}{1 - \phi^2} \sigma_{\varepsilon}^2, \rho_0 = 1,$$

$$\gamma_1 = \left( \sum_{j=0}^{\infty} \phi^j \phi^{j+1} \right) \sigma_{\varepsilon}^2 = \phi \cdot \left( \sum_{j=0}^{\infty} \phi^{2j} \right) \sigma_{\varepsilon}^2 = \frac{\phi}{1 - \phi^2} \sigma_{\varepsilon}^2, \rho_1 = \phi.$$

и, продолжая аналогичным образом, получим

$$\gamma_k = \frac{\phi^k}{1 - \phi^2} \sigma_{\varepsilon}^2, \rho_k = \phi^k.$$

Другой способ нахождения автоковариаций состоит в прямом вычислении и представляет самостоятельный интерес.

$$\gamma_1 = E(x_t x_{t-1}) = E((\phi x_{t-1} + \varepsilon_t) \cdot x_{t-1}) = \phi \sigma_x^2, \rho_1 = \phi.$$

$$\gamma_2 = E(x_t x_{t-2}) = E((\phi^2 x_{t-2} + \phi \varepsilon_{t-1} + \varepsilon_t) \cdot x_{t-2}) = \phi^2 \sigma_x^2, \rho_2 = \phi^2.$$

$$\gamma_k = E(x_t x_{t-k}) = E((\phi^k x_{t-k} + \dots + \varepsilon_t) \cdot x_{t-k}) = \phi^k \sigma_x^2, \rho_k = \phi^k.$$

### **AR (p). Уравнения Юла-Уолкера.**

Второй метод позволяет легко вычислять автоковариации в модели AR(p). Приведём вычисления для модели AR(3), для моделей высшего порядка вычисления аналогичны. Имеем

$$x_t = \phi_1 x_{t-1} + \phi_2 x_{t-2} + \phi_3 x_{t-3} + \varepsilon_t.$$

Умножая обе части на  $x_t, x_{t-1}, \dots$ , беря математические ожидания и деля на  $\gamma_0$ , получим

$$1 = \phi_1 \rho_1 + \phi_2 \rho_2 + \phi_3 \rho_3 + \sigma_\varepsilon^2 / \gamma_0$$

$$\rho_1 = \phi_1 + \phi_2 \rho_1 + \phi_3 \rho_2$$

$$\rho_2 = \phi_1 \rho_1 + \phi_2 + \phi_3 \rho_1$$

$$\rho_3 = \phi_1 \rho_2 + \phi_2 \rho_1 + \phi_3$$

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} + \phi_3 \rho_{k-3}$$

Из второго, третьего и четвёртого уравнений находим  $\rho_1, \rho_2, \rho_3$ . Из последнего уравнения находим  $\rho_4, \rho_5, \dots$ . Из первого уравнения находим дисперсию  $\sigma_x^2$

$$\sigma_x^2 = \gamma_0 = \frac{\sigma_\varepsilon^2}{1 - (\phi_1 \rho_1 + \phi_2 \rho_2 + \phi_3 \rho_3)}.$$

### **Фундаментальное представление.**

ARMA процессы с *нормальными* независимыми одинаково распределёнными ошибками являются линейными комбинациями нормальных величин, поэтому сами  $\{x_t\}$  нормально распределены. Таким образом, совместное распределение ARMA временных рядов полностью характеризуется их средним (0) и ковариациями

$E(x_t, x_{t-j})$ . (Используя обычную формулу для плотности многомерного нормального распределения, мы можем написать совместную плотность любого конечного набора значений  $\{x_t\}$ , эта плотность использует лишь ковариации). В свою очередь, все статистические свойства ряда описываются его совместными распределениями. Автоковариации дают в этом случае полную информацию о процессе. Иначе говоря:

***Если два процесса с нормальными ошибками имеют одну и ту же автоковариационную функцию, то это один и тот же процесс.***

Мы видели также, что  $AR(1)$  - это тот же процесс, что и соответствующий ему  $MA(\infty)$ , и.т.д. То, что автоковариационная функция полностью определяет процесс, является полезным фактом. Рассмотрим пример. Пусть  $\{x_t\}$  разлагается на две **гауссовские ненаблюдаемые компоненты** следующим образом:

$$x_t = y_t + z_t, \quad z_t = \delta_t, \quad y_t = v_t + \alpha v_{t-1},$$

где  $v_t - i.i.d$ ,  $\delta_t - i.i.d$ , и  $v_t$  и  $\delta_t$  независимы между собой. Каким ARMA процессом описывается  $x_t$ ? Один из способов решения этой задачи состоит в нахождении автоковариационной функции  $\{x_t\}$ , затем находят ARMA процесс с этой автоковариационной функцией. Этот процесс и даст ARMA представление для  $\{x_t\}$ . Очевидно, процессы  $y_t$  и  $z_t$  независимы, поэтому

$$Var x_t = Var y_t + Var z_t = (1 + \alpha^2)\sigma_v^2 + \sigma_\delta^2.$$

$$E(x_t x_{t-1}) = E[(v_t + \delta_t + \alpha v_{t-1})(v_{t-1} + \delta_{t-1} + \alpha v_{t-2})] = \alpha \sigma_v^2.$$

$$E(x_t x_{t-k}) = 0, \quad k \geq 2.$$

Таким образом, автоковариационная функция этого процесса такова, что первые две автоковариации  $\gamma_0$  и  $\gamma_1$  отличны от нуля, а  $\gamma_k = 0$  для  $k \geq 2$ . Как мы видели, такое поведение имеет автоковариационная функция процесса  $MA(1)$ :  $x_t = (1 + \theta L)\varepsilon_t$ . Используя формулы, полученные выше для автоковариационной функции процесса  $MA(1)$ , запишем систему уравнений, приравняв соответствующие ковариации

$$\gamma_0 = (1 + \theta^2)\sigma_\varepsilon^2 = (1 + \alpha^2)\sigma_v^2 + \sigma_\delta^2.$$

$$\gamma_1 = \theta\sigma_\varepsilon^2 = \alpha\sigma_v^2.$$

Получаем два уравнения с двумя неизвестными, которые следует решить относительно  $\theta$  и  $\sigma_\varepsilon^2$  - двух параметров представления  $x_t = (1 + \theta L)\varepsilon_t$ . Выражая  $\theta$  и  $\sigma_\varepsilon^2$  через ковариации  $\gamma_0$  и  $\gamma_1$ , получим искомое представление. Вычисление автоковариационных функций гауссовских рядов для последующего представления ряда в виде одной из стандартных моделей является одним из наиболее часто используемых приёмов при работе с временными рядами.

### **Допустимые автокорреляционные функции.**

Автокорреляционная функция играет фундаментальную роль при построении ARMA процессов. Однако не каждое множество чисел может быть множеством автокорреляций некоторого процесса. В этом параграфе мы рассмотрим вопрос: *когда множество чисел  $\{1, \rho_1, \rho_2, \dots\}$  может быть автокорреляционной функцией некоторого ARMA процесса?*

Очевидно, что коэффициенты корреляции должны по модулю не превосходить 1. Однако это условие является лишь **необходимым, но не достаточным**. Дополнительное условие состоит в том, что

дисперсия любой линейной комбинации значений  $\{x_t\}$  должна быть неотрицательна. Таким образом,

$$\text{Var}(\alpha_0 x_t + \alpha_1 x_{t-1} + \dots) \geq 0 \text{ для } \{\alpha_0, \alpha_1, \dots\}.$$

В частности,

$$\text{Var}(\alpha_0 x_t + \alpha_1 x_{t-1}) = \gamma_0 [\alpha_0 \alpha_1] \begin{bmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \end{bmatrix} \geq 0.$$

Таким образом, матрицы

$$B_1 := \begin{bmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{bmatrix}, B_2 := \begin{bmatrix} 1 & \rho_1 & \rho_2 \\ \rho_1 & 1 & \rho_1 \\ \rho_2 & \rho_1 & 1 \end{bmatrix}, \dots$$

и.т.д. должны быть неотрицательно определены. Это более сильное требование, чем  $|\rho_i| \leq 1$ . Например, детерминант второй матрицы  $B_2$  должен быть неотрицательным (также как и детерминанты её главных миноров, что влечёт  $|\rho_1| \leq 1, |\rho_2| \leq 1$ ), поэтому


$$1 + 2\rho_1^2\rho_2 - 2\rho_1^2 - \rho_2^2 \geq 0 \Rightarrow (\rho_2 - (2\rho_1^2 - 1))(\rho_2 - 1) \leq 0$$

Мы уже знаем, что  $|\rho_2| \leq 1$ , поэтому  $1 \geq \rho_2 \geq (2\rho_1^2 - 1) \Rightarrow$

$$-1 \leq \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2} \leq 1$$

Таким образом,  $\rho_1$  и  $\rho_2$  должны лежать внутри области параболической формы, показанной на рисунке





Например, если  $\rho_1 = 0,9$ , то  $2 \times (0,9)^2 - 1 = 0,62 \leq \rho_2 \leq 1$ .

Зачем нужны все эти вычисления? Тому есть, по крайней мере, две причины:

- 1) Показать, что **не всякая** последовательность автокорреляций может быть автокорреляционной функцией ARMA процесса.
- 2) Показать, что ограничения на  $\rho$  могут иметь очень сложный вид.

Сложности такого рода побуждают использовать другие методы анализа временных рядов. А именно, **спектральные методы**. Напомним, что из уравнений Юла-Уолкера следует, что автокорреляции на больших промежутках времени затухают экспоненциально быстро, т.е.  $\exists \lambda, 0 < \lambda < 1$ , такое, что  $|\gamma_j| < \lambda^j$ .

Отсюда следует, что  $\sum_{j=0}^{\infty} \gamma_j^2 < \infty$ .

## Прогнозирование и импульсные функции отклика.

Одно из наиболее важных направлений в теории ARMA процессов – прогнозирование будущих значений переменной на основе её прошлых значений. То есть мы хотим найти

$$E_t(x_{t+j}) \triangleq E(x_{t+j} | x_t, x_{t-1}, x_{t-2} \dots \varepsilon_t, \varepsilon_{t-1}, \varepsilon_{t-2}, \dots).$$

То, насколько мы можем быть уверены в нашем прогнозе, характеризуется величиной

$$Var_t(x_{t+j}) \triangleq Var(x_{t+j} | x_t, x_{t-1}, x_{t-2} \dots \varepsilon_t, \varepsilon_{t-1}, \varepsilon_{t-2}, \dots).$$

## Прогнозирование для ARMA моделей.

Мы рассмотрим несколько примеров, а потом постараемся вывести общие принципы, следующие из этих примеров.

**AR (1).** Для модели  $AR(1)$ ,  $x_{t+1} = \phi x_t + \varepsilon_{t+1}$ , имеем

$$E_t(x_{t+1}) = E_t(\phi x_t + \varepsilon_{t+1}) = \phi x_t.$$

$$E_t(x_{t+2}) = E_t(\phi^2 x_t + \phi \varepsilon_{t+1} + \varepsilon_{t+2}) = \phi^2 x_t,$$

$$E_t(x_{t+k}) = E_t(\phi^k x_t + \varepsilon_{t+k} + \dots) = \phi^k x_t.$$


Аналогично,

$$Var_t(x_{t+1}) = Var_t(\phi x_t + \varepsilon_{t+1}) = E_t(\phi x_t + \varepsilon_{t+1})^2 - \phi^2 x_t^2 = \sigma_\varepsilon^2.$$

$$\begin{aligned} Var_t(x_{t+2}) &= Var_t(\phi^2 x_t + \phi \varepsilon_{t+1} + \varepsilon_{t+2}) = \\ &= E_t(\phi^2 x_t + \phi \varepsilon_{t+1} + \varepsilon_{t+2})^2 - \phi^4 x_t^2 = (1 + \phi^2) \sigma_\varepsilon^2. \end{aligned}$$

$$Var_t(x_{t+k}) = \dots = (1 + \phi^2 + \phi^4 + \dots + \phi^{2(k-1)}) \sigma_\varepsilon^2.$$

Прогноз и стандартное отклонение для этой модели показаны на рисунке ниже



Заметим, что

$$\lim_{k \rightarrow \infty} E_t(x_{t+k}) = 0 = E(x_t),$$

$$\lim_{k \rightarrow \infty} Var_t(x_{t+k}) = \sum_{j=0}^{\infty} \phi^{2j} \sigma_{\varepsilon}^2 = \frac{1}{1 - \phi^2} \sigma_{\varepsilon}^2 = Var(x_t)$$

Интуитивно это понятно: на очень далёкое время вперёд ничего лучше не придумать в качестве прогноза для  $x_{t+k}$ , чем среднее в момент  $t$ . В качестве дисперсии этого прогноза (она характеризует точность прогноза) берётся дисперсия в момент  $t$ . Таким образом,

безусловные моменты являются пределами условных моментов. То есть, мы можем рассматривать безусловные моменты либо как пределы условных моментов  $x_t$ , когда  $t \rightarrow -\infty$ , либо как пределы условных моментов  $x_{t+j}$ , когда горизонт  $j \rightarrow \infty$ .

**МА.** Прогноз для моделей  $MA$  также считается легко. Поскольку

$$x_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots$$

Имеем

$$E_t(x_{t+1}) = E_t(\varepsilon_{t+1} + \theta_1 \varepsilon_t + \theta_2 \varepsilon_{t-1} + \dots) = \theta_1 \varepsilon_t + \theta_2 \varepsilon_{t-1} + \dots$$

$$E_t(x_{t+k}) = E_t(\varepsilon_{t+k} + \theta_1 \varepsilon_{t+k-1} + \dots + \theta_k \varepsilon_t + \theta_{k+1} \varepsilon_{t-1} + \dots) =$$

$$= \theta_k \varepsilon_t + \theta_{k+1} \varepsilon_{t-1} + \dots$$

$$Var_t(x_{t+1}) = E_t(\varepsilon_{t+1} + \theta_1 \varepsilon_t + \theta_2 \varepsilon_{t-1} + \dots)^2$$

$$= (\theta_1 \varepsilon_t + \theta_2 \varepsilon_{t-1} + \dots)^2 = \sigma_\varepsilon^2,$$

$$Var_t(x_{t+k}) = E_t(\varepsilon_{t+k} + \theta_1 \varepsilon_{t+k-1} + \dots + \theta_k \varepsilon_t + \theta_{k+1} \varepsilon_{t-1} + \dots)^2$$

$$= (\theta_k \varepsilon_t + \theta_{k+1} \varepsilon_{t-1} + \dots)^2 = (1 + \theta_1^2 + \dots + \theta_{k-1}^2) \sigma_\varepsilon^2.$$

**AR и ARMA.** При вычислении прогнозов используется то, что  $E_t(\varepsilon_{t+j}) = 0$  и  $Var_t(\varepsilon_{t+j}) = \sigma_\varepsilon^2$  при  $j > 0$ . Значение  $x_{t+j}$  представляется в виде суммы

$$x_{t+j} = \{\text{функция от } \varepsilon_{t+j}, \varepsilon_{t+j-1}, \dots, \varepsilon_{t+1}\} + \\ \{\text{функция от } \varepsilon_t, \varepsilon_{t-1}, \dots, x_t, x_{t-1}, \dots\}$$

Второе слагаемое определяет условное среднее или прогноз, а первое слагаемое определяет условную дисперсию или ошибку прогноза. Сам прогноз можно выражать как в терминах  $x$  — ов, так и в терминах  $\varepsilon$ . Например, для модели AR(1) можно написать  $E_t(x_{t+j}) = \phi^j x_t$  или  $E_t(x_{t+j}) = \phi^j \varepsilon_t + \phi^{j+1} \varepsilon_{t-1} + \dots$  поскольку  $x_t = \varepsilon_t + \phi \varepsilon_{t-1} + \dots$ .

### **Многомерные ARMA модели.**

Сейчас мы только отметим, что многомерные ARMA модели определяются аналогично одномерным, только все буквы надо понимать не как числа и одномерные переменные, а как матрицы и векторы. Конечно, как обычно, надо соблюдать некоторую осторожность с такими операциями, как транспонирование и.т.п. Многомерные прогнозы считаются во многом так же, как и прогнозы для одномерных моделей. Если мы рассмотрим, например, векторную модель MA( $\infty$ )

$$x_t = \varepsilon_t + B_1 \varepsilon_{t-1} + B_2 \varepsilon_{t-2} + \dots$$

(здесь  $x_t, \varepsilon_t$  — векторы, а  $B_i$  — матрицы), то

$$E_t(x_{t+j}) = B_j \varepsilon_t + B_{j+1} \varepsilon_{t-1} + \dots$$

$$\text{Var}_t(x_{t+j}) = \Sigma + B_1 \Sigma B_1' + \dots + B_{j-1} \Sigma B_{j-1}'.$$

Сравните с одномерным случаем

$$E_t(x_{t+j}) = E_t(\varepsilon_{t+j} + \theta_1 \varepsilon_{t+j-1} + \theta_j \varepsilon_t + \theta_{j+1} \varepsilon_{t-1} + \dots)$$

$$= \theta_j \varepsilon_t + \theta_{j+1} \varepsilon_{t-1} + \dots$$

$$\text{Var}_t(x_{t+j}) = (1 + \theta_1^2 + \theta_2^2 + \dots + \theta_{j-1}^2) \sigma_\varepsilon^2.$$

### **Пространственное представление.**

Модель AR(1) особенно удобна для вычислений, поскольку для неё сам прогноз и дисперсия ошибки прогноза могут быть вычислены рекурсивно. В этом параграфе мы объясним один полезный приём, позволяющий любой процесс преобразовать в **векторный** процесс AR(1), что приводит, в конечном счете, к созданию удобных программ, позволяющих вычислять прогнозы.

### **Представление ARMA процессов в виде векторного процесса AR(1).**

Рассмотрим, для примера, процесс ARMA (2,1)

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t + \theta_1 \varepsilon_{t-1}.$$

Представим его как **векторный** процесс авторегрессии первого порядка

$$\begin{bmatrix} y_t \\ y_{t-1} \\ \varepsilon_t \end{bmatrix} = \begin{bmatrix} \phi_1 & \phi_2 & \theta_1 \\ 1 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} y_{t-1} \\ y_{t-2} \\ \varepsilon_{t-1} \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} [\varepsilon_t]$$

Или в матричном виде

$$x_t = Ax_{t-1} + Cw_t.$$

Иногда бывает удобно переопределить матрицу  $C$  таким образом, чтобы дисперсия  $w_t = 1$ . То есть

$$C = \begin{bmatrix} \sigma_\varepsilon \\ 0 \\ \sigma_\varepsilon \end{bmatrix}, E(w_t w_t') = 1.$$

**Вычисление прогнозов с помощью векторного AR(1) представления.**

Рассмотрим векторную MA( $\infty$ ) модель

$$x_t = \sum_{j=0}^{\infty} A^j C w_{t-j}, \quad Var(w_t) = I.$$

Прогноз легко считается

$$E_t(x_{t+k}) = A^k C w_t + A^{k+1} C w_{t-1} + \dots = A^k x_t.$$

Дисперсии ошибок прогноза равны

$$x_{t+1} - E_t(x_{t+1}) = C w_{t+1} \Rightarrow Var_t(x_{t+1}) = CC'.$$

$$x_{t+2} - E_t(x_{t+2}) = C w_{t+2} + A C w_{t+1} \Rightarrow Var_t(x_{t+2}) = CC' + A C C' A',$$

$$Var_t(x_{t+k}) = \sum_{j=0}^{k-1} A^j C C' (A^j)'$$

Эти формулы особенно удобны тем, что они позволяют рекуррентно пересчитывать прогнозы и их дисперсии:

$$E_t(x_{t+k}) = AE_t(x_{t+k-1}),$$

$$Var_t(x_{t+k}) = CC' + A[Var_t(x_{t+k-1})]A'.$$